

Reporte Técnico: Redes de Hopfield Modernas

Clasificación Automática de Soplos Cardíacos en el Reto PhysioNet Murmur Challenge

Área: Deep Learning / Procesamiento de Señales Médicas Entorno: PyTorch & Linux (CachyOS)

Hardware: RTX 3060 12GB / 32GB RAM

1. Introducción y Contexto del Desafío

El **George B. Moody PhysioNet Challenge 2022** (dataset CirCor DigiScope) se centra en la detección automatizada de soplos cardíacos a partir de grabaciones de fonocardiogramas (PCG) multifocales. El objetivo principal es clasificar la condición del paciente en tres categorías mutuamente excluyentes: **Presente (Present)**, **Ausente (Absent)** o **Desconocido (Unknown)**.

El análisis de señales fonocardiográficas presenta una alta complejidad computacional debido a varios factores intrínsecos de los entornos clínicos reales:

- Ruido espurio masivo:** Las grabaciones contienen interferencias ajenas al ciclo cardíaco, tales como el roce del estetoscopio con la piel, sonidos respiratorios del paciente, llanto (en el caso de pacientes pediátricos) y ruido ambiental de la clínica.
- Arquitectura de múltiples focos auscultatorios:** Un mismo paciente posee registros tomados en distintas posiciones anatómicas (aórtico, pulmonar, tricúspide y mitral), cuyas propiedades acústicas varían notablemente.
- Fenómeno de "Aguja en un Pajar":** Un soplo patológico puede manifestarse exclusivamente durante una fracción de segundo dentro de un ciclo específico (sístole o diástole), diluyéndose a lo largo de un registro de audio de varios minutos. Esto convierte el problema en un desafío de *Aprendizaje de Múltiples Instancias (Multiple Instance Learning)*.

2. Fundamentos de las Redes de Hopfield Modernas (MHN)

Las Redes de Hopfield Clásicas, introducidas por John Hopfield en 1982, actúan como memorias asociativas binarias limitadas. Su función de energía cuadrática restringía severamente la capacidad de almacenamiento a una escala lineal respecto al número de neuronas ($C \approx 0.14 \cdot N$). Superar este límite implicaba la saturación del sistema y la aparición de "estados espurios" o falsos recuerdos.

Las **Redes de Hopfield Modernas (Dense/Continuous Hopfield Networks)**, formalizadas en el paradigma de 2020 ("*Hopfield Networks is All You Need*"), redefinen por completo la función de interacción introduciendo una transición exponencial en el paisaje de energía.

$$\text{Función de Energía Moderna: } E = - \text{lse}(\beta, X^T \xi)$$

Donde lse representa la función *Log-Sum-Exp*, β es un parámetro escalar de escala (o temperatura inversa), X es la matriz de patrones almacenados y ξ denota el estado actual de consulta. Al aplicar una derivada sobre este nuevo espacio de energía continuo, la regla de actualización del sistema en un solo paso se condensa matemáticamente en una estructura idéntica al **Mecanismo de Atención Softmax** característico de las arquitecturas Transformer:

$$\text{Regla de Actualización (Atención): } M(Q, K, V) = \text{softmax}(\beta Q K^T) V$$

Esta equivalencia matemática dota a las MHN de una capacidad de almacenamiento que escala de manera **exponencial** con la dimensionalidad del espacio, permitiendo recuperar patrones ultra-complejos de manera exacta y sin interferencias en un solo ciclo operacional.

Ventaja Conceptual Clave

A diferencia de un Transformer estándar, que calcula la auto-atención dinámicamente entre todos los elementos de la secuencia actual, la capa de Hopfield Moderna actúa como una memoria fija de patrones clínicos. Compara la señal del paciente con representaciones ideales internalizadas durante el entrenamiento.

3. Justificación de la Arquitectura para la Señal Fonocardiográfica

La aplicación de las MHN para la detección de soplos cardíacos se fundamenta en tres pilares operativos:

- Mecanismo de Hopfield Pooling (Agrupación Selectiva):** En los modelos convencionales de audio, se suele aplicar una reducción promedio global (Global Average Pooling) sobre el tiempo. Esto degrada la señal, puesto que diluye el soplo breve entre los minutos de audio normal o ruidoso. **HopfieldPooling** busca en su memoria los vectores característicos de un soplo y extrae únicamente los frames que corresponden a dicha anomalía, descartando el tejido de audio irrelevante.
- Inmunidad Intrínseca al Ruido Clínico:** Gracias al comportamiento del operador **softmax** controlado por el parámetro β , la red ignora los estados que no presenten una correlación exponencial con los patrones de interés almacenados. Los ruidos de respiración o fricción actúan como proyecciones ortogonales que no logran activar la memoria asociativa.
- Procesamiento Eficiente de Secuencias de Longitud Variable:** La señal cardíaca se proyecta hacia una matriz fija de patrones abstractos, lo que independiza la clasificación de la duración exacta del registro del audio original de PhysioNet.

4. Pipeline Detallado de la Arquitectura Propuesta

El flujo de procesamiento de datos y modelado se estructura en cuatro etapas secuenciales optimizadas de extremo a extremo:

ETAPA DEL PIPELINE	COMPONENTE / OPERACIÓN	IMPACTO Y FUNCIÓN TÉCNICA
1. Preprocesamiento	Conversión de audio <code>.wav</code> a Espectrogramas de Mel usando <code>torchaudio</code> .	Transforma la señal temporal 1D en una matriz tiempo-frecuencia 2D, capturando armónicos y transiciones sutiles del soplo.
2. Extractor (Frontend)	CNN Ligera (ResNet18 o EfficientNet-B0 modificado).	Procesa bloques del espectrograma para generar una secuencia temporal de embeddings vectoriales altamente descriptivos.
3. Memoria (MHN)	Capa de <code>HopfieldPooling</code> (<code>hopfield-layers</code>).	Compara la secuencia de embeddings contra la memoria asociativa continua. Colapsa la dimensión temporal aislando anomalías.
4. Clasificación	Capa Lineal con activación Softmax o CrossEntropy.	Mapea el vector representativo consolidado a las probabilidades de las tres clases: Presente, Ausente o Desconocido.

4.1. Interpretabilidad Clínica Integrada

Una de las mayores ventajas de este diseño es la capacidad de extraer los mapas de pesos generados por la capa de Hopfield durante la inferencia. Estos pesos indican con precisión exacta qué milisegundos de la grabación activaron el recuerdo de "Soplo" en la memoria de la red. Esto permite superponer una señal de alerta visual sobre el fonocardiograma original, ofreciendo al personal médico una herramienta completamente interpretable y auditable (evitando el efecto de "caja negra").

5. Configuración de Hardware y Entorno de Desarrollo

Dadas las especificaciones físicas del entorno del usuario, se prescribe la siguiente estrategia de asignación de recursos y optimización del sistema operativo para mitigar cuellos de botella:

CONFIGURACIÓN DE HARDWARE SELECCIONADA

- **Procesador (CPU):** AMD Ryzen 7 5700x (8 Núcleos / 16 Hilos) → Dedicado al preprocesamiento en paralelo de los espectrogramas de Mel utilizando hilos concurrentes en `DataLoader(num_workers=6)`.
- **Memoria RAM:** 32 GB DDR4 @ 2400 MHz → **Configuración Preferida** frente a los 16GB rápidos. La amplitud de la memoria evita desbordamientos (*Out of Memory*) al instanciar estructuras de datos pesadas en memoria intermedia y precalculados.
- **Tarjeta Gráfica (GPU):** NVIDIA RTX 3060 12GB VRAM → Los 12 GB permiten entrenar con tamaños de lote robustos (`batch_size=32` o `64`), crucial dado que las MHN almacenan matrices de correlación que demandan memoria de video substancial.
- **Sistema Operativo:** CachyOS (Distribución Linux optimizada basada en Arch con kernel adaptado).

5.1. Protocolo de Aislamiento de CUDA en CachyOS

Para prevenir conflictos de librerías a nivel de sistema operativo y mantener la estabilidad de CachyOS, se omite la instalación global del toolkit de CUDA. En su lugar, se encapsulan los binarios nativos directamente dentro del entorno virtual del proyecto a través de los paquetes distribuidos por los servidores de PyTorch.

El entorno de ejecución dentro del IDE PyCharm se configura mediante los siguientes comandos en la terminal aislada:

```
# 1. Crear entorno virtual aislado
python -m venv hopfield_env

# 2. Activar el entorno virtual en CachyOS
source hopfield_env/bin/activate

# 3. Instalar PyTorch con binarios de CUDA 12.1 embebidos
pip install torch torchvision torchaudio --index-url https://download.pytorch.org/whl/cu121

# 4. Instalar librería oficial de capas de Hopfield Modernas
pip install hopfield-layers librosa
```

6. Consideraciones Prácticas de Entrenamiento y Conclusión

Durante la fase de experimentación con las Redes de Hopfield Modernas, el éxito del modelo en PhysioNet dependerá críticamente de la calibración del hiperparámetro **Beta** (β). Se recomienda inicializar β utilizando el inverso de la raíz cuadrada de la dimensión de los embeddings ($\beta = 1 / \sqrt{d}$) y

posteriormente ajustarlo de forma dinámica. Un valor elevado provocará que la red se concentre exclusivamente en el frame más ruidoso, mientras que un valor excesivamente bajo transformará el módulo en un promedio simple perdiendo su ventaja asociativa.

En conclusión, el paradigma de Hopfield Moderno dota al reto PhysioNet Murmur de un marco metodológico robusto, combinando la velocidad computacional de los mecanismos de atención, la resiliencia acústica ante entornos ruidosos y una total transparencia diagnóstica ideal para el despliegue en entornos reales de salud digital.